MRI白質病変分類：現状の研究結果

集計時点：2026年11月2日 / 第1 ~ 4段階の保存済み結果
患者単位OOF評価・主解析 / 副次解析・誤分類分析の中間報告

A. 確認できた事実
MRI全体：1,154人、53,194画像。臨床CSV：1,146人。MRIのみ8人。
暫定評価対象はIDの共通集合1,146人、52,943画像。Grade 0/1/2+は551/442/153人。
除外8人はGrade 0が6人、Grade 1が2人。MRI教師ラベルを維持。
既存モデルの学習・内側検証は1,154人時点の設計のままであり、1,146人で再学習したCVではない。

評価設計
患者単位の外側5-fold CVと独立した内側holdout。各foldの内側検証は185人。
暫定評価の外側fold人数：229 / 230 / 231 / 229 / 227。
ResNet18・DeiT-small：FL + T1、全axial、224px。主解析は最大クラス確率の高い上位5枚を平均しargmax。
副次解析は保存済みの内側選択Grade 0/1規則。外側テストでの閾値調整は行っていない。

B. 未解決事項 / D. 解釈の限界
MRIと臨床のラベル不一致1人、臨床の派生ラベル不整合1人は未修正（同一患者）。
本評価は探索済みコホートの条件付き解析。外部・前向きの独立検証ではない。
MRI画素の医学的目視確認、病変注釈、scanner/DICOM特性、近似重複は未検証。
スライス予測は患者ラベルを継承しており、病変が見える画像の注釈ではない。

結論の要点
Grade 1のRecallは副次規則で改善するが、Grade 0誤分類が増える。
残るGrade 1取りこぼしには選択に関連する予測パターンがある一方、Grade 0誤分類例にもGrade 1スライス予測が多い。
従来の上位5枚argmaxを主解析として維持。新しい学習・閾値・集約・ensembleは採用していない。

C. 暫定1,146人：主解析と副次解析

モデル	Accuracy	Macro-F1	Bal.Acc	AUC	Recall 0	Recall 1	Recall 2+
ResNet18 主解析	61.78%	0.5952	0.5875	0.7906	87.30%	31.45%	57.52%
ResNet18 副次解析	63.87%	0.6276	0.6104	0.7906	81.49%	44.12%	57.52%
DeiT-small 主解析	63.26%	0.6122	0.5943	0.7922	84.21%	40.50%	53.59%
DeiT-small 副次解析	64.66%	0.6350	0.6124	0.7922	76.95%	53.17%	53.59%
従来型CNN 参考・主解析	57.07%	0.4515	0.4537	0.7058	80.94%	42.76%	12.42%

AUC：3クラスmacro one-vs-rest ROC-AUC。副次規則は確率を変更しないためAUCは不変。
従来型CNNは80px・axial 9 ~ 15、評価画像16,037枚の別pipeline。画像 / 学習fingerprintの再監査は不完全。
同じ患者の参考比較であり、性能差をarchitectureだけの効果と解釈しない。

モデル	解析	クラス	人数	Precision	Recall	F1	OvR AUC
R18	主	Grade 0	551	0.6005	0.8730	0.7115	0.7890
R18	主	Grade 1	442	0.5991	0.3145	0.4125	0.7085
R18	主	Grade 2+	153	0.7788	0.5752	0.6617	0.8743
R18	副	Grade 0	551	0.6387	0.8149	0.7161	0.7890
R18	副	Grade 1	442	0.5909	0.4412	0.5052	0.7085
R18	副	Grade 2+	153	0.7788	0.5752	0.6617	0.8743
DeiT	主	Grade 0	551	0.6253	0.8421	0.7177	0.7870
DeiT	主	Grade 1	442	0.5987	0.4050	0.4831	0.6984
DeiT	主	Grade 2+	153	0.7810	0.5359	0.6357	0.8912
DeiT	副	Grade 0	551	0.6656	0.7695	0.7138	0.7870
DeiT	副	Grade 1	442	0.5817	0.5317	0.5556	0.6984
DeiT	副	Grade 2+	153	0.7810	0.5359	0.6357	0.8912

C. 混同行列と追加誤分類コスト

ResNet18 主解析：行 = MRI教師、列 = 予測

教師	予測0	予測1	予測2+
0	481	68	2
1	280	139	23
2+	40	25	88

ResNet18 副次解析：行 = MRI教師、列 = 予測

教師	予測0	予測1	予測2+
0	449	100	2
1	224	195	23
2+	30	35	88

DeiT-small 主解析：行 = MRI教師、列 = 予測

教師	予測0	予測1	予測2+
0	464	86	1
1	241	179	22
2+	37	34	82

DeiT-small 副次解析：行 = MRI教師、列 = 予測

教師	予測0	予測1	予測2+
0	424	126	1
1	185	235	22
2+	28	43	82

副次規則の変更は元の予測0→1のみ。
Grade 1正解：ResNet18 139→195人、DeiT-small 179→235人（各56人増）。
Grade 0→1誤分類：ResNet18 68→100人（+32）、DeiT-small 86→126人（+40）。
正解患者総数：708→732人 / 725→741人。Grade 2+正解は88/153人 / 82/153人で不変。
真のGrade 2+で既に誤判定だった10人 / 9人も予測0→1となるが、正解にはならない。

C. 不確実性と改善しなかった比較

モデル	指標	副 - 主	95%区間
R18	accuracy	0.0209	+0.0061 ~ +0.0358
R18	macro_f1	0.0324	+0.0191 ~ +0.0455
R18	macro_roc_auc	0.0000	+0.0000 ~ +0.0000
R18	balanced_accuracy	0.0229	+0.0109 ~ +0.0346
R18	grade0_recall	-0.0581	-0.0780 ~ -0.0399
R18	grade1_recall	0.1267	+0.0973 ~ +0.1539
R18	grade2plus_recall	0.0000	+0.0000 ~ +0.0000
DeiT	accuracy	0.0140	-0.0017 ~ +0.0288
DeiT	macro_f1	0.0228	+0.0105 ~ +0.0353
DeiT	macro_roc_auc	0.0000	+0.0000 ~ +0.0000
DeiT	balanced_accuracy	0.0180	+0.0061 ~ +0.0300
DeiT	grade0_recall	-0.0726	-0.0944 ~ -0.0526
DeiT	grade1_recall	0.1267	+0.0973 ~ +0.1561
DeiT	grade2plus_recall	0.0000	+0.0000 ~ +0.0000

患者単位の対応あり・クラス層別bootstrap：各モデル1,000回、seed 20261102。
固定済みモデル・観測クラス構成に条件付けたpercentile区間。学習fold依存、過去の探索、ラベル不確実性を解消しない。
Exact McNemar（Accuracyのみ）：ResNet18 p=0.01375、DeiT-small p=0.12535。Macro-F1の検定ではない。

モデル	集約	Accuracy	Macro-F1	Recall 1	Recall 2+
cnn	top5	61.78%	0.5952	31.45%	57.52%
cnn	all_slice_mean	58.99%	0.4541	45.02%	9.15%
vit	top5	63.26%	0.6122	40.50%	53.59%
vit	all_slice_mean	58.90%	0.4335	52.71%	3.92%

全スライス平均はGrade 1 Recallを上げる一方、Grade 2+ RecallとMacro-F1を大幅に低下させた。
固定cached確率の診断比較であり、全スライス平均は採用していない。
内側選択の重み（fold 1 ~ 5）：ResNet18 2,2,2,1.5,2 / DeiT-small 1.5,2,1.25,2,2。

C. 残る誤分類の特徴とfold差

Grade 1→0残存：ResNet18 224人、DeiT-small 185人。
Grade 1スライス予測があるのに選択5枚は全て0：180/224人（80.4%）、155/185人（83.8%）。
両モデル共通のGrade 1誤分類：241→178人。両方とも予測0：228→166人。
追加救済の共通部分11人、どちらかで救済101人。新Grade 0誤分類の共通部分10人、どちらかで追加誤分類62人。
これらは重複を除いた事象の集計であり、ensembleの性能ではない。

モデル	群	人数	G1予測slice割合中央値	同割合のIQR
R18	G1救済	56	50.00%	41.58% ~ 59.09%
R18	G0新誤分類	32	53.31%	36.57% ~ 61.78%
R18	G1残存0	224	17.39%	8.33% ~ 30.64%
DeiT	G1救済	56	52.27%	40.76% ~ 66.10%
DeiT	G0新誤分類	40	54.17%	41.67% ~ 64.03%
DeiT	G1残存0	185	18.75%	8.70% ~ 28.26%

救済Grade 1と新誤分類Grade 0の分布は重なる。IQRは分布の幅であり信頼区間ではない。
二値特徴の区間はWilson 95%。差の有意差検定・新しいclassifierの学習は実施していない。

モデル	fold	G1救済	G0新誤分類	正解増減	Macro-F1差
cnn	1	16	9	7	0.0453
cnn	2	10	5	5	0.0331
cnn	3	12	8	4	0.0240
cnn	4	2	4	-2	0.0001
cnn	5	16	6	10	0.0548
vit	1	9	5	4	0.0183
vit	2	20	24	-4	0.0109
vit	3	8	3	5	0.0215
vit	4	11	5	6	0.0348
vit	5	8	3	5	0.0306

DeiT-smallの新Grade 0誤分類24/40人（60%）はfold 2。20人救済対24人新誤分類で正解数は4人減。
全10比較のMacro-F1点推定は上昇するが、AccuracyはResNet18 fold 4とDeiT-small fold 2で低下。

B・D・E. 限界、次の検証、出典

未確認事項と誤解を避ける注意
・スライス予測やaxial番号から病変の存在・位置・医学的なラベル正当性を断定しない。
・Grade 1残存0 / Grade 0新誤分類群ではmodality欠落・内部axial gap・重複flagは0。
全体にはgap flagが2人あり、保持正解のGrade 0 / Grade 1各1人。画素品質の保証ではない。
・内側で選ばれた重みが外側で追加誤分類を招く原因 (scanner、撮像、ラベル、calibration) は未特定。
・fold依存モデル / 重みは群比較を交絡し得る。人数5未満のfold特徴は理由を明記して非表示。
・患者情報、個人別予測、画像、臨床データはPDFに含めない。臨床変数の関連・multimodal fittingも未実施。

次の優先順位
1. ViT fold 2を中心に、保存済み内側 / 外側Grade 0/1スコア分布を比較する。外側で規則は再調整しない。
2. Grade 0/1定義を確認し、残存Grade 1・救済Grade 1・新Grade 0誤分類の真に盲検の専門家比較を準備する。
現在の339人のprivate候補表はモデル情報を含む分析者用であり、盲検資料ではない。
3. 新しい集約・modality制限・順序分類・MIL・ensembleは、開発データで仮説を固定し独立確認してから検討。

第1段階：全1,154人	Accuracy	Macro-F1	Recall 1	Recall 2+
cnn	61.79%	0.5948	31.31%	57.52%
vit	63.34%	0.6126	40.54%	53.59%
original_cnn	57.19%	0.4520	42.79%	12.42%

上表は評価対象を共通集合に限定する前の結果。後の1,146人評価との差を学習改善と解釈しない。
出典：mri-vit-classification/outputs/ 内の下記保存済み集約報告。SHA-256で現物を照合。

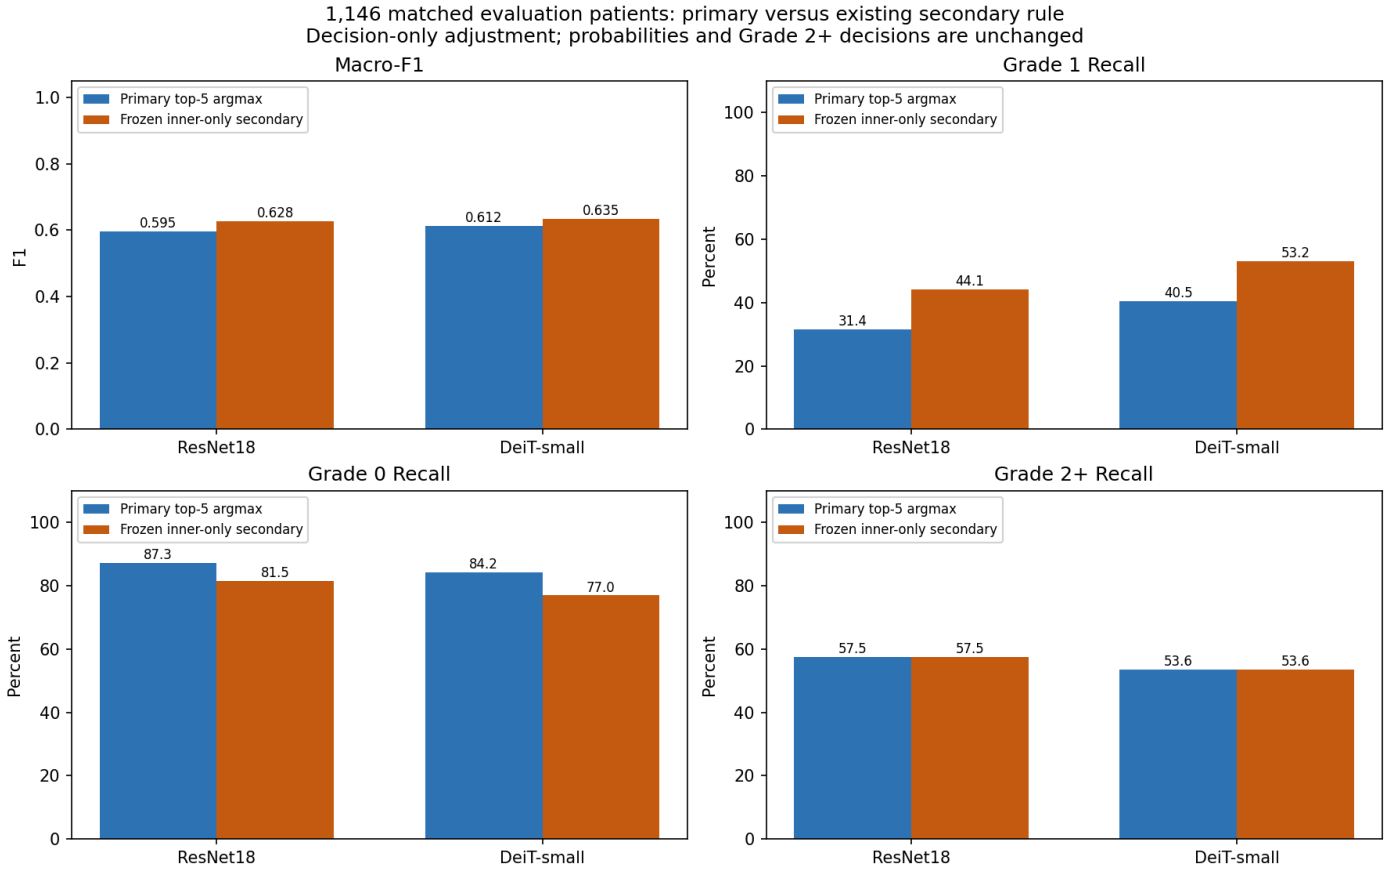
第1段階：stage1_summary.json
SHA-256: 3c2ffc2586ab0f1318ad2da6135716f1be8aae90c2723bb754f9fda196eaf1b9

第2段階：stage2_summary.json
SHA-256: f1893217b7a1849f5979f170cf10e2ac18b1e7d96bcb5f556777f75e1dbc4da1

第3段階：stage3_summary.json
SHA-256: 5cd8dca5c9700d433e6b3f6c086b9370d15863891bfb8b58b416e7f6a4daa300

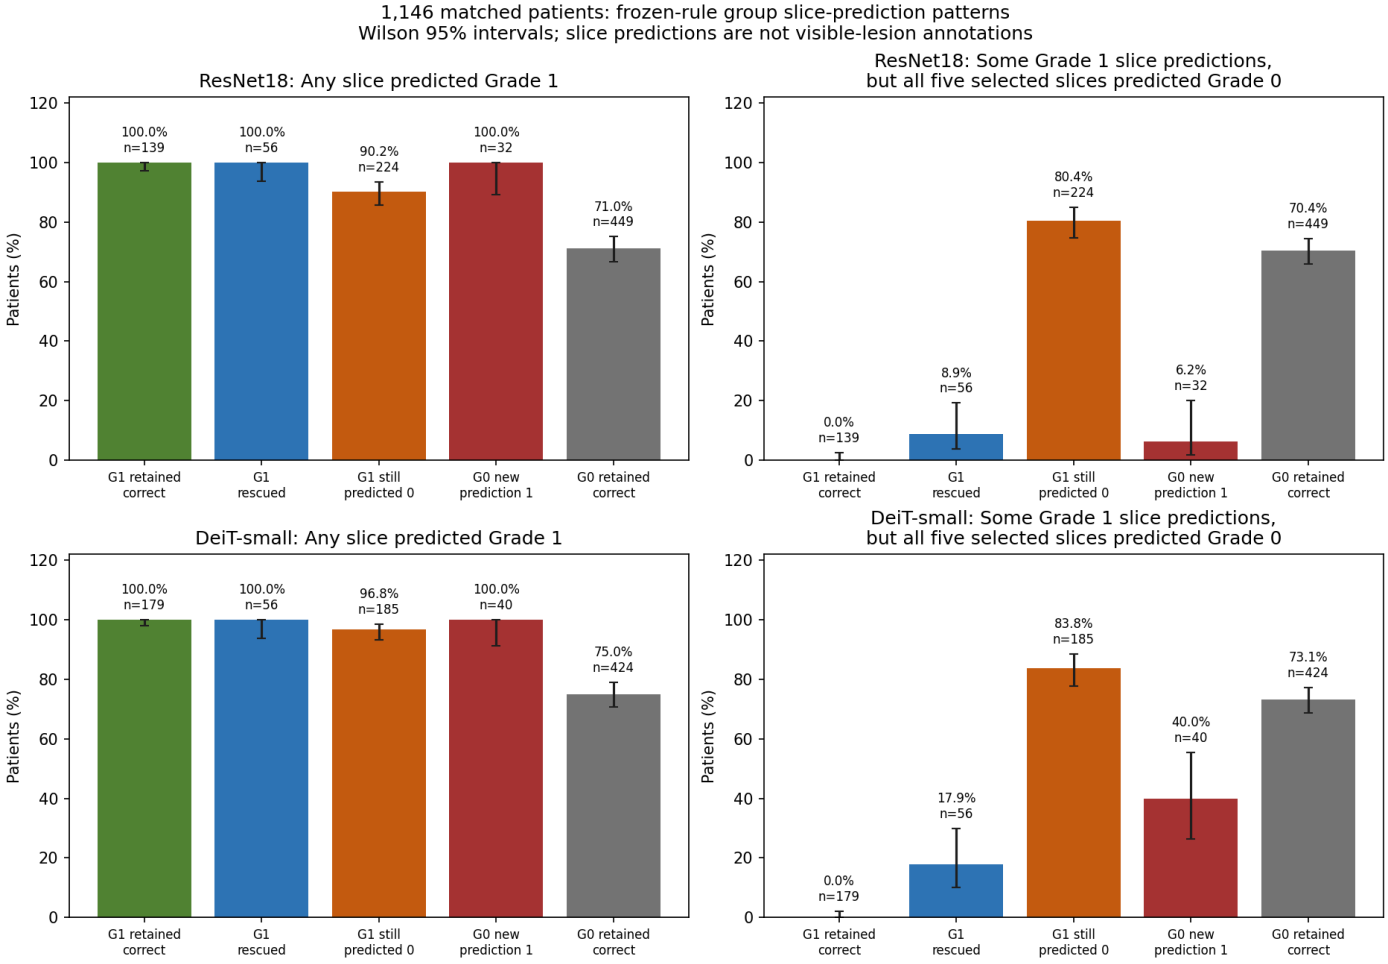
第4段階：stage4_summary.json
SHA-256: fa09a994ae76b9c6eb984783f5488c3d67b5cc6bd9a18b347425e6b1009d889c

図1：主解析 / 副次解析の改善とコスト



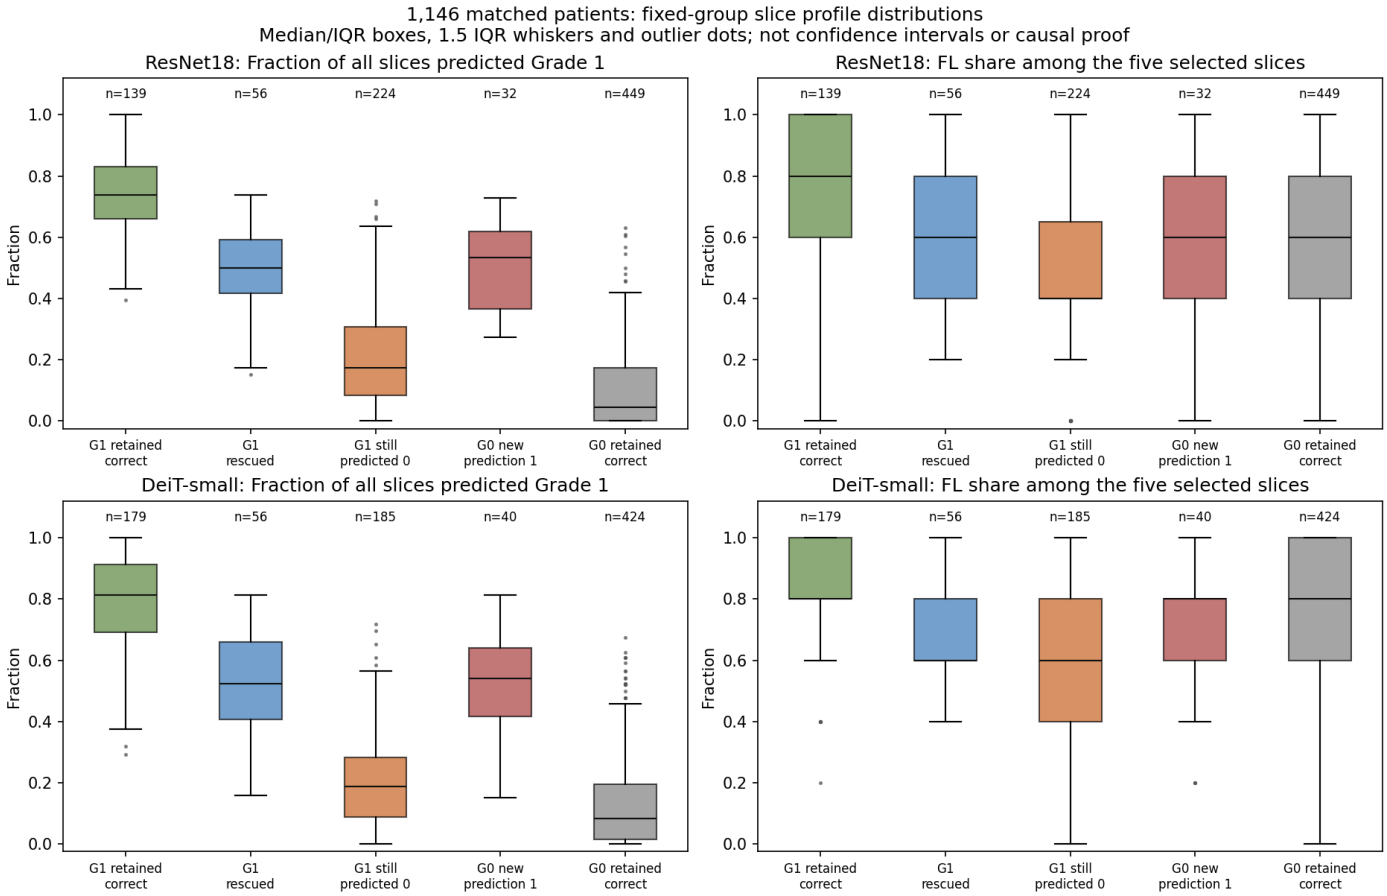
図は保存済み集約出力。患者ID・画像画素は含まない。
図中の群はコホートの部分集合。スライス予測は病変注釈ではなく、図のみから因果・有意差を推定しない。

図2：残る取りこぼしの予測・選択パターン



図は保存済み集約出力。患者ID・画像画素は含まない。
図中の群はコホートの部分集合。スライス予測は病変注釈ではなく、図のみから因果・有意差を推定しない。

図3：救済と新誤分類の分布の重なり



図は保存済み集約出力。患者ID・画像画素は含まない。
図中の群はコホートの部分集合。スライス予測は病変注釈ではなく、図のみから因果・有意差を推定しない。