MRIからの大脳白質病変グレード分類

CNNとVision Transformerの患者単位・画像単位評価

データ、リーケージ対策、最新結果、探索試験を一つに整理

1,154

患者 / 5-fold OOF

53,194

画像 / FL + T1

0 / 1 / 2+

患者gradeの3クラス分類

対象：2026-10-06までに確認済みの結果 | 資料作成：2026-10-15
患者ID・個別MRI画像は掲載していない。外部検証・臨床実装の完了報告ではない。

現時点で言えること

主目的：未知患者のgradeを推定し、CNNとViTの有用性を妥当に比較する

01 主評価：ViTの全体的な優位性は未確立

患者macro-F1 CNN 0.5948 / ViT 0.6126
差の95% CIは0を含む。差がないことの証明でもない。

02 課題：grade 0と1の判別、画像と患者の違い

ViTはgrade 1の再現率が高い一方、grade 0の再現率は低い。
画像ラベルは患者gradeの引き継ぎであり、病変の画像別正解ではない。

03 探索試験：自己教師あり特徴の有効性は未確認

6条件を内側185患者で比較。主評価の1,154患者OOFとは別。
新手法の採用を裏付ける改善はまだ示されていない。

データ構成と3クラスの定義

全axialを維持。主実験はFL（FLAIR）とT1を使用し、T2は含めない。

教師ラベル	患者数	患者構成比	画像数
grade 0	**557**	**48.27%**	**25,696**
grade 1	**444**	**38.47%**	**20,480**
grade 2+ (元2・3・4)	**153**	**13.26%**	**7,018**



FL **26,588画像 / 1,149患者**

T1 **26,606画像 / 1,151患者**

同一患者がFLとT1の両方に含まれるため、モダリティ別患者数は足し合わせない。
grade 2+は少数クラス。元grade 2・3・4を区別する5クラス性能は、この結果から主張しない。

画像の正解と患者の正解は同じ意味ではない

教師ラベル：患者全体の病変grade

画像単位 / 53,194画像

1枚ずつ予測し、患者gradeと比較する。
病変が写っていない断面にも同じgradeが付く。

患者単位 / 1,154患者

全画像から上位5枚の確率を平均する。
集約確率のargmaxを患者予測とする。

top-5の基準 = 各画像における全クラスの最大予測確率

grade 0を確信する画像も選ばれる。「病変らしい上位5枚」を意味しない。
画像単位のgrade 2+再現率を、病変検出感度や局在精度とは呼ばない。

学習・重み選択・最終評価を患者ごとに分離

外側5-fold CV + 内側20% holdout。従来の外側評価による重み選択を修正した。

TRAIN	INNER VALIDATION	OUTER TEST
738 / 739患者	185患者	231 / 230患者
重みを学習	lossで重みを選択 grade 0/1ルールを固定	固定済みモデルを評価 学習rootと物理的に分離

5回の外側評価を結合：全1,154患者を1回ずつOOF予測

患者重複 0 ｜ 外側の結果でepoch・集約方法・判定ルールを選ばない

単一の内側holdoutであり、完全なnested hyperparameter CVではない。内側患者を加えた再fitなし。
既に探索した同一コホートを使用しており、外部・前向きの未見評価ではない。

共通の学習条件と実行監査

項目	CNN	ViT
モデル	ResNet18	DeiT-small / patch16
入力・データ	224 px / FL + T1	同左
学習	30 epochs / batch 16	同左
最適化	AdamW / lr 3e-5	同左
正則化	weight decay 0.1	同左 + drop / path 0.1
共通設定	cosine / smoothing 0.1	同左 / 共通の画像拡張
最良重みの選択	inner画像lossのみ	inner画像lossのみ

10学習すべて完了。コード・依存環境・設定・分割・重みの固定情報を照合済み。
異患者間のbyte完全一致画像：0組。近似重複や医学的ラベルの正しさまで保証するものではない。

患者単位の主評価：全体差は確定していない

1,154患者 / 外側5-fold OOF / top-5 / 元のargmax。主指標はmacro-F1。

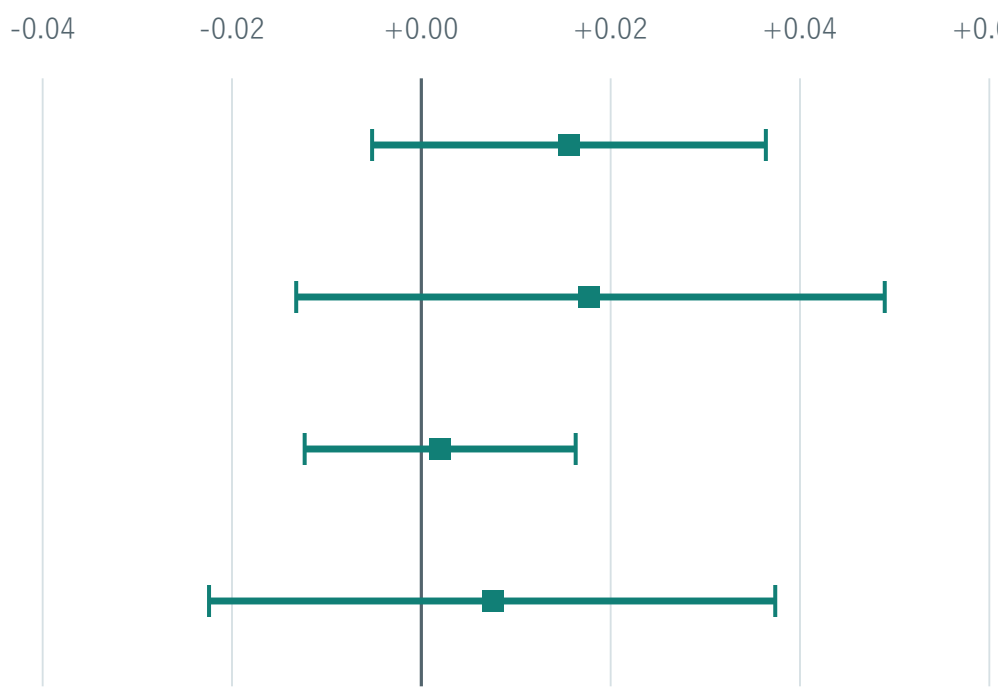
指標	CNN	ViT	ViT - CNNの95% CI
Accuracy	**0.6179**	**0.6334**	**[-0.0052, +0.0364]**
Macro-F1	**0.5948**	**0.6126**	**[-0.0132, +0.0490]**
Macro-AUC	**0.7910**	**0.7929**	**[-0.0123, +0.0163]**
Balanced accuracy	**0.5869**	**0.5945**	**[-0.0224, +0.0374]**

正答率：CNN 61.79% ／ ViT 63.34%

各指標は全患者を結合した値。fold別指標の単純平均ではない。
3クラスmacro平均であり、二値診断性能や臨床使用可能性を表すものではない。

患者単位の差と95%信頼区間

右：ViTの指標が高い / 左：CNNの指標が高い / 縦線：差0



	ViT - CNN［95% CI］
Accuracy	+0.0156［-0.0052, +0.0364］
Macro-F1	+0.0178［-0.0132, +0.0490］
Macro-AUC	+0.0019［-0.0123, +0.0163］
Balanced accuracy	+0.0075［-0.0224, +0.0374］

患者単位・grade層別・対応付きbootstrap 10,000回。いずれの区間も0を含む。
学習済みモデルを固定した患者標本の不確実性。再学習のばらつき・外部汎化は含まない。

患者の誤分類：grade 1から0への予測が多い

行：真の患者grade / 列：予測grade。各セルは患者数と行内割合。

CNN / ResNet18

	grade 0	grade 1	grade 2+
0	486 87.3%	69 12.4%	2 0.4%
1	282 63.5%	139 31.3%	23 5.2%
2+	40 26.1%	25 16.3%	88 57.5%

再現率 0 / 1 / 2+ **0.873 / 0.313 / 0.575**

ViT / DeiT-small

	grade 0	grade 1	grade 2+
0	469 84.2%	87 15.6%	1 0.2%
1	242 54.5%	180 40.5%	22 5.0%
2+	37 24.2%	34 22.2%	82 53.6%

再現率 0 / 1 / 2+ **0.842 / 0.405 / 0.536**

grade 0/1の判定調整：副解析として評価

確率の再学習や校正ではなく、予測0/1の判定のみを変更する。主評価とは区別する。

元の予測が0/1のとき　weight × p1 > p0 ならgrade 1

候補 {1, 1.25, 1.5, 2} を内側macro-F1で選択し、外側評価前に固定。
同点は小さいweight。元のgrade 2+予測・確率・AUCは変更しない。

患者指標：調整前 → 後	CNN	ViT
Accuracy	0.6179 → 0.6386	0.6334 → 0.6482
Macro-F1	0.5948 → 0.6272	0.6126 → 0.6361
grade 1再現率	0.3131 → 0.4392	0.4054 → 0.5338

上表は1,154患者OOFの副解析。予測grade 2+の集合は不変。
調整後だけを主結果として採用すると、評価結果を見て方式を選ぶことになる。

改善と代償：grade 1を拾うほどgrade 0を失う

患者単位：調整前 → 後	CNN	ViT
grade 1 → 0 の患者数	282 → 226	242 → 185
grade 0 → 1 の患者数	69 → 101	87 → 127
grade 0再現率	0.8725 → 0.8151	0.8420 → 0.7702

CNN Macro-F1の増分

+0.0324 [+0.0189, +0.0463]

VIT Macro-F1の増分

+0.0235 [+0.0108, +0.0371]

下段：調整後 - 前の95% CI。患者grade層別・対応付きbootstrap 10,000回（探索的）。
grade 0の過大評価を含むため、macro-F1向上だけで臨床的な適切さは判断しない。

画像単位の評価：Accuracyは両者とも約56%

53,194画像 / 1,154患者 / 各モデルで全画像を外側評価1回。再学習・grade 0/1調整なし。

指標	CNN	ViT
Accuracy	**0.5665**	**0.5647**
Macro-F1	**0.4609**	**0.4544**
Macro-AUC	**0.6941**	**0.7004**
Balanced accuracy	**0.4567**	**0.4521**

正答率：CNN 56.65% ／ ViT 56.47%

患者単位の主評価と同じinner-best-loss重み・前処理を使用し、1枚ずつargmaxで判定。
患者内の画像は相関するため、53,194の独立症例として扱わない。AUCは点推定のみ。

画像の誤分類：grade 2+の再現率が低い

行：患者から引き継いだgrade / 列：画像予測grade。各セルは画像数と行内割合。

CNN / ResNet18

	grade 0	grade 1	grade 2+
0	20,300 79.0%	5,212 20.3%	184 0.7%
1	10,997 53.7%	8,765 42.8%	718 3.5%
2+	2,548 36.3%	3,402 48.5%	1,068 15.2%

再現率 0 / 1 / 2+ **0.790 / 0.428 / 0.152**

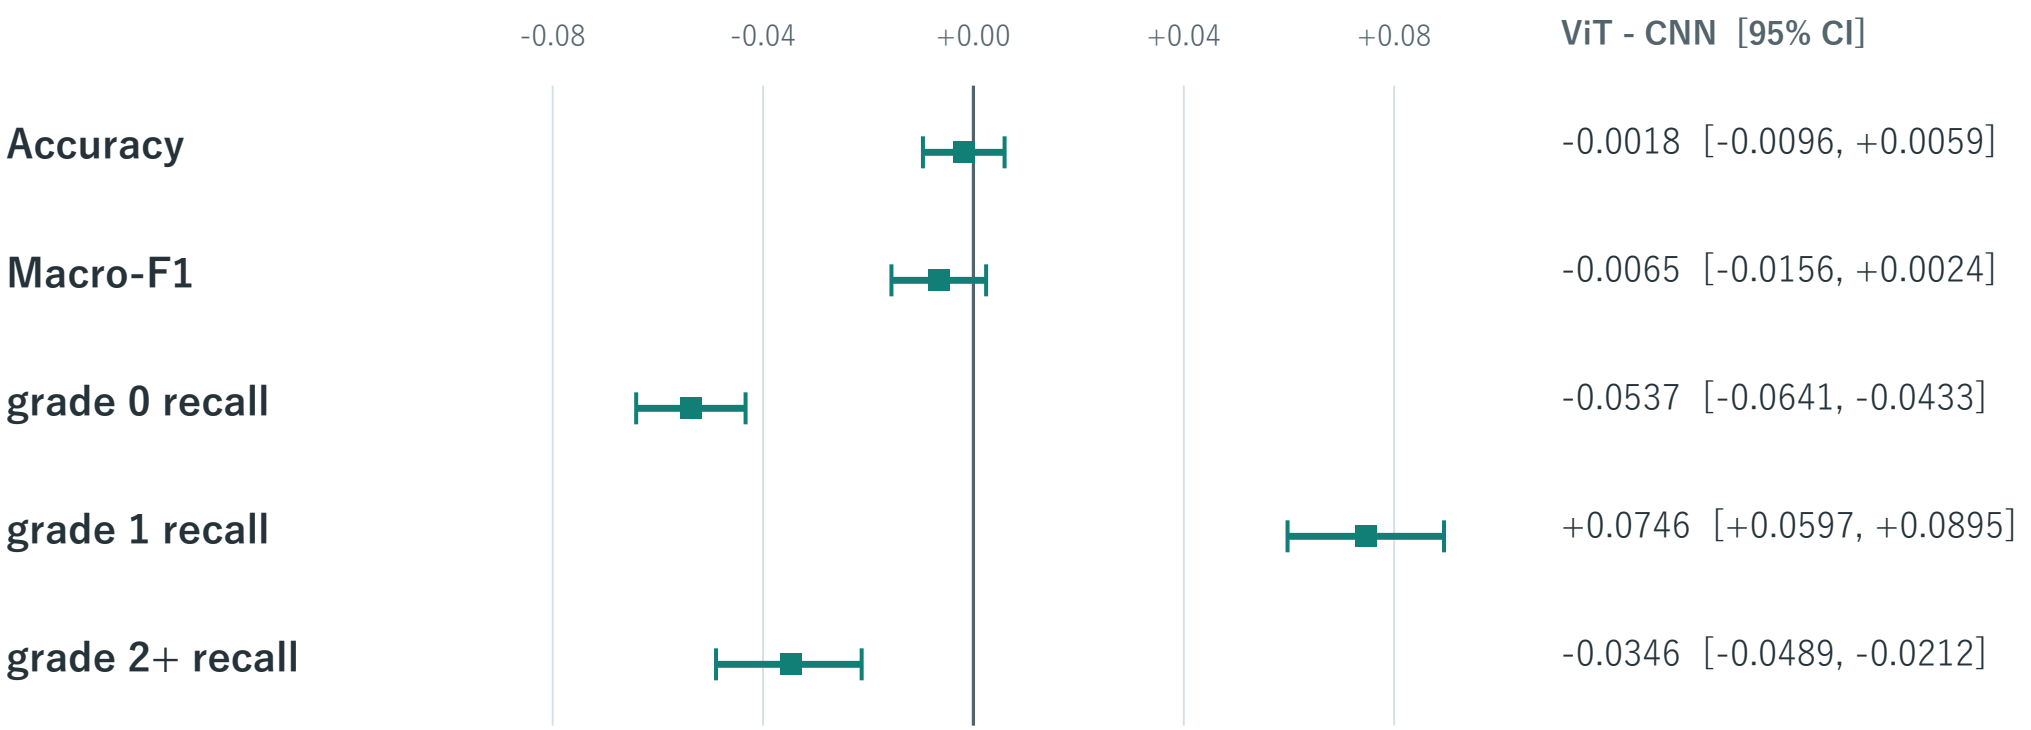
ViT / DeiT-small

	grade 0	grade 1	grade 2+
0	18,921 73.6%	6,707 26.1%	68 0.3%
1	9,772 47.7%	10,292 50.3%	416 2.0%
2+	1,939 27.6%	4,254 60.6%	825 11.8%

再現率 0 / 1 / 2+ **0.736 / 0.503 / 0.118**

画像の信頼区間は患者クラスタで求める

同じ患者の全画像をひとまとまりで再標本化。外側fold × 患者gradeで層別。



対応付きbootstrap 10,000回。Accuracy・macro-F1の差の区間は0を含む。
ViTはgrade 1再現率が高く、0と2+は低い。副指標の多重比較には注意。AUCのCIは未算出。

FLとT1の画像別結果

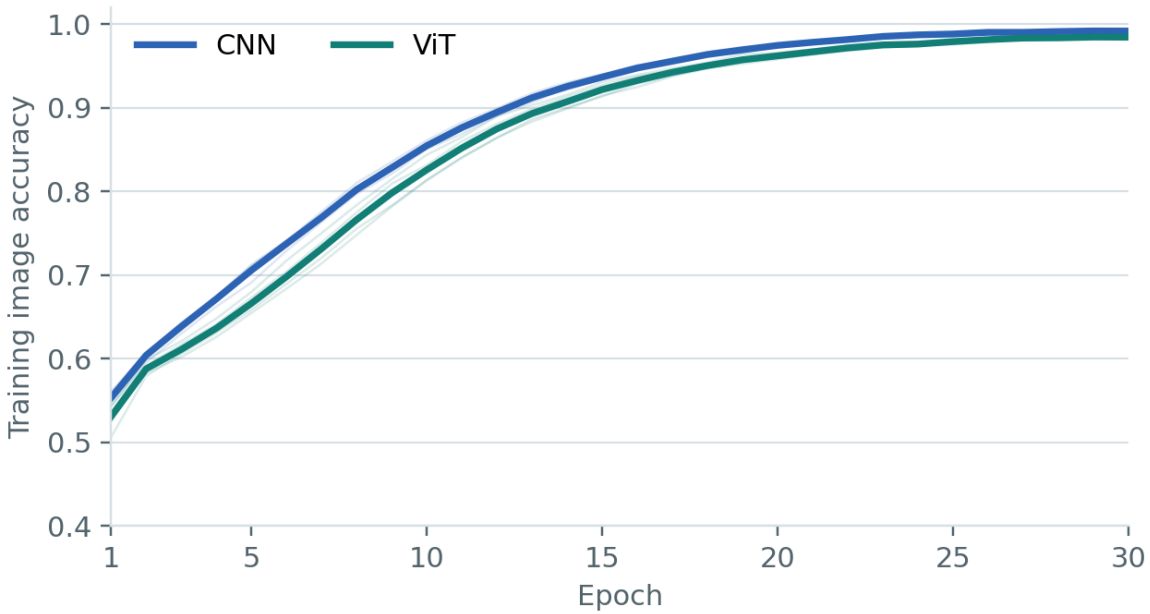
同じFL + T1学習済みモデルの評価画像を分けた記述的集計。別々に学習した比較ではない。

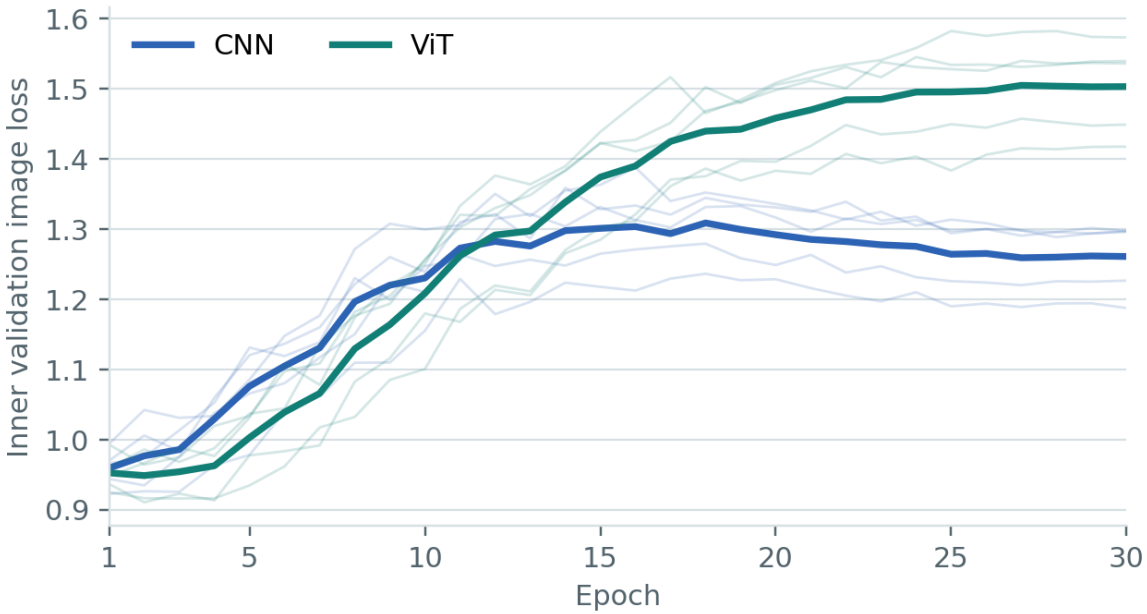
画像集合 / モデル	画像数	Accuracy	Macro-F1	Macro-AUC
FL / CNN	**26,588**	**0.5893**	**0.5113**	**0.7244**
FL / ViT	**26,588**	**0.5875**	**0.5090**	**0.7315**
T1 / CNN	**26,606**	**0.5437**	**0.4026**	**0.6622**
T1 / ViT	**26,606**	**0.5419**	**0.3887**	**0.6664**

この集計では両モデルともFLの値が高い。ただし撮像法・患者の構成が関与する可能性がある。
FLの因果的優位性、FL単独学習の有効性、FLとT1を併用する利得は、この表だけでは判断できない。

学習を長く続けるだけでは改善しなかった

細線：各fold / 太線：5-fold平均。左は学習画像Accuracy、右は内側画像loss。





CNN 選択epoch（fold 1→5）：1 / 1 / 2 / 1 / 1

VIT 選択epoch（fold 1→5）：1 / 1 / 2 / 2 / 3

全10学習の最良inner-loss epochは1〜3。後半は学習Accuracyが高くても内側lossは悪化。
既に最良重みを採用済みであり、早期停止だけで現在の評価値が上がるわけではない。

自己教師あり特徴の小規模試験：6条件

fold 1の訓練738患者・内側185患者のみ。外側患者の画像・予測は参照していない。

凍結済み特徴抽出器	全画像の平均	FL/T1別 平均 + 標準偏差
DINO ResNet50	**0.5729**	**0.5437**
DINO ViT-S16	**0.5237**	**0.5792**
DINOv2 ViT-S14	**0.5041**	**0.5454**

表：内側185患者のmacro-F1。全6条件を実行・保存・再現確認。

患者特徴をロジスティック回帰で分類。標準化とC選択は訓練患者内3-foldのみ。
DINOはImageNet1k、DINOv2はLVD-142M事前学習。データ量・patch幅が違い、構造だけの比較ではない。
この凍結特徴試験は、MRIへの全層fine-tuningや局所パッチ・患者文脈モデルの試験ではない。

探索試験の結論：採用を支える改善は未確認

DINO ViT-S16 + FL/T1別平均・標準偏差を、同じ内側185患者で比較する。

同一185患者の比較	Macro-F1	grade 2+再現率
DINO ViT-S16 / FL・T1別集約	**0.5792**	**0.4000**
既存CNN（grade 0/1調整後）	**0.6000**	**0.6800**
既存ViT（grade 0/1調整後）	**0.5666**	**0.2800**

既存CNNとの差：-0.0207 95% CI [-0.1082, +0.0588]

6条件の観察後の探索的比較。同じ内側集合で既存モデル・調整ルールも選択されている。
条件付きbootstrap・多重比較未補正で、独立した新手法の有効性検証ではない。
この手法の大規模5-fold学習への移行は見送り。否定的結果も保持する。

残る限界と、まだ検証していないこと

評価の独立性	同一コホートを過去に探索。内側選択へ修正しても、外部検証に相当しない。
ラベルの妥当性	専門家による盲検再判定は保留。元ラベルの修正・難例の選択除外はしていない。
臨床情報	照合可能1,146患者・画像のみ8患者。grade整合性の不一致1患者が未解決。 臨床情報はモデルに入力しておらず、融合解析の準備ゲートは未通過。
統計の範囲	CIは学習済みモデル固定。再学習変動・外部施設差・臨床有用性を含まない。
モデルの解釈	Attentionや高信頼画像は医学的根拠の証明ではない。局在・体積を未評価。

次の仮説：局所情報と患者内文脈を扱う

未実装・未学習の研究計画。ここまでの実測結果とは区別する。

目的はViTを勝たせることではなく、強みが出る条件を検証すること

比較軸	独立に集約	患者内の文脈を利用
CNNの局所特徴	**対照条件**	**集約機構の効果**
ViTの局所特徴	**特徴抽出器の効果**	**特徴 × 文脈の効果**

全axial・FL/T1・相対的な画像順序を維持し、患者単位で学習する。
学習予算・探索範囲・選択方法を揃え、別の開発分割で再現性を先に確認。

局所パッチ + 患者文脈モデルの改善は、まだ示されていない。
次の確証的な評価には新規患者・外部データを優先し、結果確認後の選択は探索として明示する。

補足：fold別の患者数と主評価

患者数とmacro-F1。主結果は下表の単純平均ではなく、全外側OOF予測を結合して算出する。

fold	訓練	内側	外側	CNN F1	ViT F1
1	**738**	**185**	**231**	**0.6253**	**0.6129**
2	**738**	**185**	**231**	**0.6006**	**0.6300**
3	**738**	**185**	**231**	**0.5424**	**0.6605**
4	**738**	**185**	**231**	**0.6217**	**0.6351**
5	**739**	**185**	**230**	**0.5503**	**0.5077**

OOF：学習・選択に使わなかった外側foldの予測。
Macro-F1：クラス別F1の等重み平均。Recall：真の各gradeを正しく予測した割合。
Macro-AUC：各クラスのone-vs-rest AUCの平均。Accuracyと同義ではない。

出典と再現性

各ページのS番号は下記に対応。パスはmri-vit-classificationからの相対表記。

S1 患者単位の主評価
outputs/cv5_all_axial_3class_selection_safe_v1/oof_summary/paired_bootstrap/paired_bootstrap_results.json

S2 画像単位の評価・監査
outputs/selection_safe_image_oof_20261006/{image_summary,frozen_evaluation}.json

S3 grade 0/1調整
outputs/cv5_all_axial_3class_selection_safe_v1/{model}/foldN/metrics/grade01_secondary.{csv,json}

S4 全10学習のログ
outputs/cv5_all_axial_3class_selection_safe_v1/{model}/foldN/logs/{model}_epoch_log.csv

S5 自己教師あり6条件
outputs/foundation_patient_probe_20261006/fold1/pilot_results.json

S6 探索試験の再現検査・比較
outputs/foundation_patient_probe_20261006/fold1/post_pilot_validation.json

S7 学習・選択・評価の固定設計
config/SELECTION_SAFE_CV_PROTOCOL_20261002.md

S8 環境・臨床データの監査
ANALYSIS_READINESS_20261002.md / REMEDIATION_20261002.md

S9 今後の研究仮説
experiments/RESEARCH_DIRECTION_20261006.md

掲載値は保存済みJSON・CSVから生成。資料用集計・出典SHA-256は outputs/research_summary_20261015 に保存。