

Vision Transformer を用いた大脳白質病変グレード分類の患者単位評価

浅川 天夢 1), 石井 一夫 1)

公立諏訪東京理科大学工学部情報応用工学科

概要: 本研究では, 脳 MRI 画像から大脳白質病変の重症度を予測するため, Vision Transformer (ViT) と CNN を患者単位で比較した. FLAIR・T1 強調画像の全アキシャル 53,194 枚, 1,154 名を grade 0, grade 1, grade 2 以上の 3 クラスに統合し, 患者重複のない 5 分割交差検証を実施した. 各患者の高信頼 5 スライスを平均した out-of-fold 評価では, ViT の macro ROC-AUC は 0.8100, CNN は 0.7891 で, 差 0.0209 の 95%信頼区間は 0.0062–0.0357 であった. 一方, Accuracy と macro-F1 の差は有意でなかった.

Patient-Level Evaluation of Cerebral White Matter Lesion Grade Classification Using Vision Transformer

Ten Asakawa1), Kazuo Ishii1)

Department of Applied Information Engineering, Faculty of Engineering, Suwa University of Science

Abstract: We compare a Vision Transformer (ViT) with a convolutional neural network for patient-level classification of cerebral white matter lesion grades. A leakage-free five-fold cross-validation was performed on 53,194 FLAIR and T1-weighted axial images from 1,154 patients, using three classes: grade 0, grade 1, and grade 2 or higher. Patient probabilities were obtained by averaging the five most confident slices. The out-of-fold macro ROC-AUC was 0.8100 for ViT and 0.7891 for CNN; the paired difference was 0.0209 (95% CI: 0.0062–0.0357). Differences in accuracy and macro-F1 were inconclusive.

1. はじめに

大脳白質病変は脳 MRI の T2 強調画像や FLAIR 画像で高信号を示し, 加齢や高血圧と関連する. その進行は脳卒中や認知機能低下のリスクと関連するため, 画像から重症度を客観的に評価する技術が求められる[1, 2].

先行研究では CNN を用いた grade 0 から grade 4 の分類が行われた[1]. 提案発表時には画像単位分割による Accuracy 0.9209 を比較基準としていたが, 患者 ID を再点検すると, 同一患者の別スライスが学習集合と評価集合に重複する構造が判明した. そこで本研究では評価単位を患者に改め, 患者重複のない条件で Vision Transformer (ViT) [3]と CNN を比較する.

2. 方法

2.1 対象と分類課題

対象は脳ドック受診者 1,154 名で, FLAIR 画像と T1 強調画像の全アキシャル 53,194 枚を用いた. ラベルは患者単位で付与されている. grade 3 および 4 は各 39 名, 8 名と少ないため, grade 2 から 4 を統合し, grade 0 (557 名), grade 1 (444 名), grade 2 以上 (153 名) の 3 クラス分類とした.

項目	条件
対象	1,154 名, 53,194 画像
入力	FLAIR+T1, 全アキシャル
クラス	grade 0 / 1 / 2 以上
分割	患者単位層化 5-fold
評価	全患者の OOF 予測

表 1: データと評価プロトコル

2.2 比較条件と患者集約

ViT には DeiT-small (patch 16, 入力 224×224) [4], CNN には ResNet18 を用いた. 両者は同一 fold, 30 epoch, AdamW, 学習率 3×10^{-5} , weight decay 0.1, cosine scheduling, label smoothing 0.1, 同一データ拡張で学習した. 各 fold で validation loss が最小のモデルを採用した.

患者ごとに全スライスを推論し, 最大クラス確率が高い上位 5 スライスを選択してクラス確率を平均した. 5-fold の各 validation 予測を連結し, 全 1,154 名の out-of-fold (OOF) 予測を得た. 不確実性はクラス層化 paired bootstrap 10,000 回による 95%信頼区間 (CI) で評価した.

3. 結果

OOF 評価を表 2 に示す. ViT は 4 指標すべてで CNN を上回った. ただし, 95% CI が 0 を含まなかった差は macro ROC-AUC のみであり, 差は 0.0209 (95% CI: 0.0062–0.0357) であった. Accuracy の McNemar 検定は $p=0.598$ であり, 正解率の優位性は示されなかった.

指標	CNN	ViT	ViT-CNN (95% CI)
Accuracy	0.6282	0.6352	+0.0069 (−0.0156, 0.0295)
Macro-F1	0.6001	0.6134	+0.0133 (−0.0135, 0.0399)
Macro AUC	0.7891	0.8100	+0.0209 (0.0062, 0.0357)
Balanced Acc.	0.5995	0.6132	+0.0137 (−0.0112, 0.0386)

表 2: 患者単位 5-fold OOF 評価




図 1: CNN と ViT の患者単位 OOF 性能

クラス別再現率は, grade 0 で CNN 0.8636, ViT 0.8402, grade 1 で 0.3468, 0.3851, grade 2 以上で 0.5882, 0.6144 であった. いずれの差の 95% CI も 0 を含んだ. 特に grade 1 は両モデル共通の課題であり, 境界症例の画像所見やラベルの揺らぎを臨床的に確認する必要がある.

4. 考察

患者単位の分割へ変更した結果, 画像単位分割で得られていた高い Accuracy は再現せず, 医療画像では患者リーケージを防ぐ評価設計が不可欠であることが確認された. 一方, 同一条件の 5-fold 比較で ViT は macro ROC-AUC を改善した. Self-Attention による広域特徴の利用が, 患者の重症度を順位づける能力に寄与した可能性がある. ただし Accuracy と macro-F1 の差は小さく, ViT が分類性能全般で優れるとは結論できない.

本研究は全アキシャルを入力し, 固定した top-5 集約で患者予測を得た. これにより手動の断面範囲指定を避けたが, スライス選択は確信度に基づく後処理であり, 患者内の断面間関係を直接学習していない. また, 本プロトコルは探索用 validation での検討後に固定したため, 外部データに対する完全な未検証評価ではない.

5. おわりに

大脳白質病変の 3 クラス分類について, 患者重複のない 5-fold OOF 評価で ViT と CNN を比較した. ViT は macro ROC-AUC で小さいが統計的に支持される改善を示した一方, Accuracy と macro-F1 の優位性は確認できなかった. 今後は外部検証または反復交差検証を行うとともに, 全スライスを患者単位で学習する MIL や Transformer 集約へ発展させ, grade 1 の識別改善を検討する.

参考文献

- [1] 竹村典晃, 『畳み込みニューラルネットワークを用いた大脳白質病変のグレード予測』, 公立諏訪東京理科大学卒業論文, 2023.
- [2] S. DeBette and H. S. Markus, “The clinical importance of white matter hyperintensities on brain magnetic resonance imaging,” *BMJ*, vol. 341, c3666, 2010.
- [3] A. Dosovitskiy et al., “An Image is Worth 16×16 Words: Transformers for Image Recognition at Scale,” *ICLR*, 2021.
- [4] H. Touvron et al., “Training data-efficient image transformers & distillation through attention,” *ICML*, pp. 10347–10357, 2021.