

2023 年度 卒業論文

畳み込みニューラルネットワークを用いた
大脳白質病変のグレード予測

公立諏訪東京理科大学
工学部 情報応用工学科

T120100 竹村 典晃

指導教員 石井 一夫 教授

提出日 令和 6 年 2 月 5 日

Abstract

Large cerebral white matter lesions are ischemic changes that occur in the brain, and hypertension is considered the greatest risk factor for these lesions. When large white matter lesions are observed, it is important to prevent further progression by controlling blood pressure and other measures.

In "Prediction of Cerebral White Matter Lesions Using Medical Examination Data," we constructed a model to predict the presence or absence of cerebral white matter lesions by logistic regression analysis using medical examination data of patients who underwent the Brain Checkup Course. In this study, we aimed to establish a diagnostic method for cerebral white matter lesions using MRI images, and to further investigate the relationship between the MRI images and the examination items in the medical checkup data.

There are approximately 25 MRI images of a single patient's head, from the top of the head to near the eyeballs. For the order of these images, we defined the unit of axial for convenience. We varied conditions such as the location and extent of images to be loaded into the convolutional neural network model, and verified changes in discrimination performance on the test data. Co-occurrence network diagrams were also used to evaluate the relationship between the grade of cerebral white matter lesions and some of the biochemical test items, which were treated as categorical variables, and the progression of cerebral white matter lesions and the patient's health status, which were illustrated in the following figure.

The convolutional neural network showed the highest discrimination performance when the images loaded into the model had 80 pixels per side, axial from 9 to 15, and FLAIR and T1-weighted images. The AUC for each grade was 0.9814 for grade 0, 0.9800 for grade 1, 0.9905 for grade 2, 0.9977 for grade 3, and 0.9998 for grade 4. In the co-occurrence network diagram, patients with no or mild cerebral white matter lesions, such as grade 0 and grade 1, were closer to normal blood pressure, while grade 2 patients were closer to (isolated) systolic hypertension, indicating that patients with higher grade cerebral white matter lesions were more likely to have severe suggesting that patients with higher grade cerebral white matter lesions tend to suffer from more severe hypertension.

In grade prediction using a convolutional neural network, a larger value of range tends to increase accuracy because the number of images used for training increases. On the other

hand, an extreme increase in range is thought to have decreased accuracy because the training data includes images on the oculomotor and parietal sides, where no cerebral white matter lesions are seen. In the co-occurrence network diagram, it is considered that co-occurrence relationships were not formed and drawn as nodes due to the small number of samples with grade 3 or higher, and the association between patients with severe cerebral white matter lesions and health examination items could not be adequately observed. We would like to investigate the association with cerebral white matter lesions by including a wider range of items, such as history of cerebral infarction.

要旨

大脳白質病変は、脳に起こる虚血性の変化であり、その最大のリスク因子は高血圧であるとされている。また、脳卒中のリスク因子でもあり、大脳白質病変が見られた場合、血管管理などにより、さらに進行しないよう対処することが重要である。

我々は、「健診データを用いた脳白質病変予測」において、脳ドックコース受診者の健診データを用い、ロジスティック回帰分析による大脳白質病変の有無を予測するモデルを構築した。本研究では、MRI 画像を用いた大脳白質病変の診断方法を確立し、さらに健診データの検査項目との関連を調査することを目的とした。

患者一人の頭部 MRI 画像は、頭頂部から眼球付近にかけて、およそ 25 枚の画像が存在する。これらの画像の順番に対して、便宜的に axial という単位を定義した。畳み込みニューラルネットワークのモデルに読み込ませる画像の位置と範囲の広さなどの条件を変更し、テストデータにおける判別性能の変化を検証した。また、共起ネットワーク図を用いて、大脳白質病変のグレードと生化学検査項目の一部をカテゴリ変数として扱い、大脳白質病変の進行度と患者の健康状態との関連を図示して評価を行った。

畳み込みニューラルネットワークで、最も高い判別性能を示したのは、モデルに読み込ませる画像の一辺を 80pixel, axial を 9~15, FLAIR 画像と T1 強調画像を用いたときであった。各 grade の AUC は、grade0 が 0.9814, grade1 が 0.9800, grade2 が 0.9905, grade3 が 0.9977, grade4 が 0.9998 となった。共起ネットワーク図では、grade0 や grade1 のように、大脳白質病変を有しない、または軽度の大脳白質病変を有する患者は正常な血圧との距離が近く、grade2 の患者は（孤立性）収縮期高血圧との距離が近く、より高いグレードの大脳白質病変を有する患者ほど、重度の高血圧を罹患している傾向が示唆された。

畳み込みニューラルネットワークによるグレード予測では、range の値が大きいほど、学習に用いる画像数が増加するため、精度が上昇する傾向にある。一方で、range を極端に増やすと、大脳白質病変が見られない眼球側や頭頂部側の画像が学習データに含まれるため、精度は低下したと考えられる。共起ネットワーク図においては、グレード 3 以上のサンプル数が少ないために共起関係が形成されず、ノードとして描画されなかったと考えられ、高度の大脳白質病変を有する患者と健診項目との関連性を十分に見ることができなかった。脳梗塞との既往歴など、より幅広い項目を含めて、大脳白質病変との関連性を調べていきたい。

目次

1.	はじめに	1
1.1.	背景	1
1.2.	目的	1
2.	研究対象	1
2.1.	対象	1
2.2.	倫理的配慮	5
3.	データおよび方法	5
3.1.	実験環境, ソフトウェアおよびライブラリのバージョン	5
3.2.	大脳白質病変のグレード評価	6
3.3.	畳み込みニューラルネットワーク	8
3.4.	共起ネットワーク図	10
4.	結果	11
4.1.	畳み込みニューラルネットワーク	11
4.1.1.	画像サイズの変更	11
4.1.2.	アキシャルの変更	12
4.1.3.	撮影方法による違い	18
4.1.4.	学習曲線	19
4.1.5.	グレード別評価	20
4.2.	共起ネットワーク図	22
5.	考察	24
	参考文献	25
	謝辞	27

1. はじめに

1.1. 背景

近年の日本の少子高齢化の進行と平均寿命の延伸に伴い、健康寿命が注目されるようになってきた [1] [2]. 疾病予防や介護予防などにより、平均寿命と健康寿命の差を短縮できれば、生活の質の低下の防止、個人の医療負担の削減、社会保障負担の軽減などの効果が期待できる.

大脳白質病変は認知症と関連があるとされており [3], 進行した大脳白質病変は、脳卒中などの脳血管障害や糖尿病のリスク因子といわれている [4] [5]. また、大脳白質病変の進行と、認知機能の低下には有意な相関があるという研究が報告されている [6] [7].

大脳白質病変は、大脳の微小血管障害によって引き起こされる虚血性の変化である [8]. 大脳白質病変の最大のリスク因子は高血圧であるとされている [4], [9]. 大脳白質病変は、自覚症状がなく進行するため、日常生活で大脳白質病変の進行を見逃しやすく、脳ドックを受診することが有効である [10].

大脳白質病変が認められた場合、血圧管理や生活習慣の改善などにより、さらに進行しないよう対処することが重要である.

1.2. 目的

我々は、「健診データを用いた脳白質病変予測」 [4]において、脳ドックコース受診者の健診データを用い、ロジスティック回帰分析による大脳白質病変の有無を予測するモデルを構築した. 本研究では、MRI 画像を用いた大脳白質病変の診断方法を確立し、さらに健診データの検査項目との関連を調査することを目的とした.

2. 研究対象

2.1. 対象

2016 年 4 月 1 日から 2017 年 10 月 31 日までに、一般社団法人巨樹の会新武雄病院において、人間ドック脳ドックコースにおいて頭部 MRI 検査と血液検査を受けた 1146 名を対象とした.

本研究の対象を図 1 に示す. 「健診データを用いた脳白質病変予測」 [4]で対象とした 1904 名のレコードのうち、T1 強調画像、T2 強調画像、FLAIR 画像の 3 種類すべてが揃って

いないレコードを除外した 1146 名を対象とした. grade 別のレコード数は, grade0 が 551 件で 44.1%, grade1 が 441 件で 38.5%, grade2 が 107 件で 9.3%, grade3 が 39 件で 3.4%, grade4 が 8 件で 0.7%であった.

患者背景を表 1 に示す. 血液検査などの生化学検査項目の平均値や標準偏差と, 問診票による投薬治療の有無や, 飲酒・喫煙習慣などの割合などをグループ別に示した. 全ての患者, 0 から 4 の grade 別, grade2~4 の 7 群に分けた. また, grade1~4 に関しては, grade0 の値を用いて, 連続変数は t 検定を行い, カテゴリカル変数はカイ二乗検定を行った. 有意水準は 0.05 とし, ボンフェローニ補正を行った.

各変数は次の項目を表す.

PS [11]: 頸動脈プラークスコア

age: 年齢

LDL: LDL

HDL: HDL

LH: LDL/HDL

TG: 中性脂肪

HbA1c: HbA1c

BS: 血糖値

SBP: 収縮期血圧

DBP: 拡張期血圧

the number of plaque: 頸動脈プラークの数

BMI: BMI

Male: 男性

metabolic syndrome: メタボリックシンドローム

smoking habit: 現在タバコを習慣的に吸っていますか

medication to reduce pressure: 降圧剤の使用の有無

medication to reduce blood sugar or insulin injection: インスリンまたは血糖を下げる薬の使用の有無

medication to reduce a level of cholesterol: 抗コレステロール薬の使用の有無

amount of drinking per day (in terms of Sake): 1日あたりの飲酒量

drink habit: アルコールを飲む頻度

また、生化学検査項目の数値を用い、A-G, X-Z の 10 個の疾患にカテゴリ変数化した.

A: 正常血圧

B: 正常高値血圧

C: 高値血圧

D: I 型高血圧

E: II 型高血圧

F: III 型高血圧

G: (孤立性) 収縮期高血圧

X: obesity, 肥満

Y: diabetes, 糖尿病

Z: dyslipidemia, 脂質異常症

ただし、A-G に関して、SBP と DBP が異なる分類に属する場合にはより高いほうの分類に組み入れた [12].

検定の結果、帰無仮説の棄却が保留された項目を以下に示す.

PS: grade1, grade2, grade3

age: grade2, grade3, grade4

HbA1c: grade1, grade2

BS: grade3

SBP: grade1, grade2, grade4

DBP: grade1

the number of plaque: grade1, grade2, grade3

smoking habit: grade3, grade4

medication to reduce pressure: grade4

medication to reduce blood sugar or insulin injection: grade4

正常血圧: grade4

表 1 患者背景

grade	n	n1	0	1	2	3	4	2-4
factor		1146	551	441	107	30	8	154
PS, mean (sd)		0.94 (1.8)	0.53 (1.3)	1.04 (1.8)	1.56 (2.2)	2.92 (2.9)	4.94 (4.9)	2.08 (2.7)
age, mean (sd)		55.72 (11.7)	49.62 (10.8)	59.82 (9.7)	64.61 (7.7)	67.82 (4.9)	71.88 (3.9)	65.81 (7.2)
LDL, mean (sd)		120.52 (30.7)	119.67 (31.8)	122.36 (29.8)	120.16 (28.8)	115.23 (29.4)	108.75 (26.0)	118.32 (28.8)
HDL, mean (sd)		60.25 (15.0)	59.02 (14.4)	61.65 (15.5)	61.45 (15.9)	58.08 (13.4)	62.13 (12.7)	60.63 (15.1)
LDL, mean (sd)		2.13 (0.8)	2.16 (0.8)	2.12 (0.8)	2.07 (0.7)	2.09 (0.7)	1.83 (0.6)	2.07 (0.7)
TC, mean (sd)		110.39 (38.2)	111.97 (36.2)	107.03 (39.9)	118.96 (31.2)	100.51 (49.2)	120.38 (51.0)	114.56 (38.9)
FibcA1c, mean (sd)		5.77 (0.7)	5.67 (0.6)	5.84 (0.7)	5.91 (0.7)	5.94 (0.6)	6.0254	5.92 (0.7)
BS, mean (sd)		104.77 (19.8)	102.85 (17.6)	105.89 (21.7)	107.12 (21.0)	111.41 (20.9)	110.63 (9.0)	108.39 (20.5)
SBP, mean (sd)		124.22 (18.6)	120.40 (16.4)	126.65 (19.2)	130.00 (20.0)	132.28 (25.0)	137.38 (16.7)	130.96 (21.2)
DBP, mean (sd)		74.22 (12.1)	72.67 (11.5)	75.62 (12.2)	76.11 (13.1)	73.87 (14.9)	80.88 (7.6)	75.79 (13.4)
the number of plaque, mean (sd)		0.52 (0.9)	0.30 (0.7)	0.60 (1.0)	0.89 (1.1)	1.44 (1.4)	2.13 (1.9)	1.09 (1.3)
BxAL, mean (sd)		23.19 (3.4)	23.15 (3.4)	23.18 (3.3)	23.10 (3.2)	24.23 (3.4)	23.00 (6.7)	23.38 (3.5)
Male, n (%)		582 (50.8%)	313 (56.8%)	203 (46.0%)	43 (40.2%)	20 (51.3%)	3 (37.5%)	66 (42.9%)
metabolic syndrome, n (%)		867 (75.7%)	443 (80.4%)	321 (72.8%)	77 (72.0%)	21 (53.8%)	0.1321	103 (66.9%)
		111 (9.7%)	52 (9.4%)	42 (9.5%)	10 (9.3%)	7 (17.9%)	0.3731	17 (11.0%)
		168 (14.7%)	56 (10.2%)	78 (17.7%)	20 (18.7%)	11 (28.2%)	0.05955	34 (22.1%)
		204 (17.8%)	121 (22.0%)	65 (14.7%)	13 (12.1%)	4 (10.3%)	0.2189	18 (11.7%)
smoking habit, n (%)		279 (24.3%)	71 (12.9%)	139 (31.5%)	39 (36.4%)	24 (61.2%)	6 (75.0%)	69 (44.8%)
medication to reduce pressure, n (%)		82 (7.2%)	17 (3.1%)	41 (9.2%)	17 (15.9%)	5 (12.8%)	0.1497	24 (15.6%)
medication to reduce blood sugar or insulin injection, n (%)		182 (15.9%)	50 (9.1%)	89 (20.2%)	30 (28.0%)	9 (23.1%)	0.1251	43 (27.9%)
medication to reduce a level of cholesterol, n (%)		737 (64.3%)	320 (58.1%)	306 (69.4%)	75 (70.1%)	29 (74.4%)	0.3793	111 (72.1%)
amount of drinking per day, n (%)		288 (25.1%)	160 (29.0%)	93 (21.1%)	26 (24.3%)	8 (20.5%)	0.5106	35 (22.7%)
(in terms of Sake)		360-54ml	53 (9.4%)	30 (6.8%)	3 (2.8%)	2 (5.1%)	0.6653	5 (3.2%)
		more than 54ml	34 (3.0%)	12 (2.7%)	3 (2.8%)	1	0.4286	3 (1.9%)
drink habit, n (%)		486 (42.4%)	19 (3.4%)	200 (45.4%)	48 (44.9%)	17 (43.6%)	0.8752	68 (44.2%)
		180-360ml	165 (29.6%)	133 (30.2%)	37 (34.6%)	8 (20.5%)	0.3032	3 (17.5%)
		345 (30.1%)	168 (30.5%)	108 (24.5%)	22 (20.6%)	15 (38.5%)	0.6105	47 (30.5%)
		315 (27.5%)	168 (30.5%)	153 (34.5%)	28 (26.2%)	9 (23.1%)	0.0483	68 (44.2%)
A, n (%)		457 (39.9%)	266 (48.3%)	153 (34.5%)	28 (26.2%)	0.09564	0.0483	38 (24.7%)
B, n (%)		193 (16.8%)	88 (16.0%)	73 (16.6%)	20 (18.7%)	11 (28.2%)	0.2716	32 (20.8%)
C, n (%)		244 (21.3%)	119 (21.6%)	93 (21.1%)	23 (21.5%)	6 (15.4%)	0.623	37 (23.8%)
D, n (%)		75 (6.5%)	32 (5.8%)	34 (7.7%)	6 (5.6%)	2 (5.1%)	1	9 (5.8%)
E, n (%)		38 (3.3%)	12 (2.2%)	20 (4.5%)	3 (2.8%)	1	0.3498	6 (3.9%)
F, n (%)		12 (1.0%)	3 (0.5%)	4 (0.9%)	1	2 (5.1%)	0.5455	5 (3.2%)
G, n (%)		127 (11.1%)	31 (5.6%)	64 (14.5%)	25 (23.4%)	6 (15.4%)	0.2185	32 (20.8%)
X (cholesterol), n (%)		307 (26.8%)	145 (26.3%)	115 (26.1%)	14 (13.1%)	5 (12.8%)	0.1993	47 (30.5%)
Y (diabetes), n (%)		92 (8.0%)	32 (5.9%)	46 (10.4%)	70 (65.4%)	0.7964	0.2356	21 (13.6%)
Z (dyslipidemia), n (%)		680 (59.3%)	327 (59.3%)	262 (59.4%)	70 (65.4%)	17 (43.6%)	0.3362	91 (59.1%)

*When SBP and DBP belonged to different classifications, they were included in the higher classification.




図 1 研究対象

2. 2. 倫理的配慮

本研究は、公立諏訪東京理科大学の倫理審査委員会の承認を得て実施した。患者の個人情報保護のため、第三者による連結不可能匿名化処理を行い、データはパスワード付き記録媒体へ保存し研究以外でのデータの使用は行っていない。

3. データおよび方法

3. 1. 実験環境, ソフトウェアおよびライブラリのバージョン

以下に、使用したハードウェアのスペックを示す。

CPU: Intel Core i9-10850K

RAM: 64.0 GB

GPU: NVIDIA GeForce RTX 3090

OS: Windows 11 Pro

OS バージョン: 22H2

ソフトウェア環境として、Anaconda3-2021.05 を用いた。

以下に、使用した主なライブラリとバージョンを示す。

Python==3.8.17

Cudatoolkit==1.3.1

cudnn==8.2.1

tensorflow-gpu==2.6.0

keras==2.6.0

numpy==1.23.5

scikit-learn

pandas

seaborn==0.12.2

3.2. 大脳白質病変のグレード評価

大脳白質病変は、病変が見られない grade0 から、最も病変が多く見られる grade4 までの 5 段階で、MRI 画像を用いて評価が行われる [13]。

図 2 に大脳白質病変のある患者と無い患者の画像を示す。図 2 上段が grade4、図 2 下段が grade0 である。上段の左から 3 枚目と 4 枚目の、左脳と右脳の中央部に見られる白く描画されている領域と、上段の左から 5 枚目に見られる白い斑点が大脳白質病変である。この白い領域の面積が大きいほど、高いグレードとして評価される。

本研究で使用した MRI の撮影方法には、T1 強調画像、T2 強調画像、FLAIR 画像の 3 種類が存在する。図 3 に撮影方法別の MRI 画像を示す。いずれの画像も同じ患者、同じ部分の画像で、grade は 4 である。左の画像が T1 強調画像、中央の画像が T2 強調画像、右が FLAIR 画像である。T2 強調画像は、水を高信号として白く描写し、T1 強調画像は、T2 強調画像の白黒を反転させたように写る。FLAIR 画像は、T2 強調画像における、髄液などの正常な水を低信号として黒く描写した画像であり、脳室周囲の病巣などを判断する際に有用な撮影方法である。目視においては、FLAIR 画像で最もはっきり病変を見ることができ、T2 強調画像もほぼ同程度に病変が見られる [14]。T1 強調画像では、病変部分が周囲よりも濃い灰色として描画される。

また、本研究では、解析の都合上、便宜的に axial と range という概念を定義した。

一般に, axial とは CT や MRI の撮影において, 人が直立した際に横断する方向の軸位断を指す. 本研究で用いた MRI は, 一人の患者につき, 25 枚程度の横断画像が存在するため, 眼球側を 1 として昇順に axial の値を割り当てた. range は, 用いた axial の数を表す. axial は, 25 枚程度ある画像のうち, どの部位を取り出して, 畳み込みニューラルネットワークの学習と評価に用いたかを表し, range は, 学習と評価に用いた axial の範囲の広さを表す. 例えば, 図 4 に赤枠で示した範囲のみを取り出した時, axial は 12 から 16, range は 5 と表す.




図 2 典型的な白質病変有りの患者と無しの患者の MRI




図 3 撮影方法別 MRI




図 4 本研究における axial と range の定義

3.3. 畳み込みニューラルネットワーク

畳み込みニューラルネットワークを用いて、アキシシャルの取り方や、MRI 画像の撮影方法の違いによる大脳白質病変の grade 判別精度の変化を検証した。

大脳白質病変は脳室周囲に見られることが多く、眼球寄りや頭頂部寄りの部分などでは、高度の大脳白質病変を有する患者でも、病変は現れない。畳み込みニューラルネットワークの学習データに、病変がみられない範囲の画像を用いると、精度に影響が出る懸念がある。そこで、学習と評価に用いるアキシシャルの位置と数を変更した。

また、脳ドックのガイドライン 2019 [15]において、MRI 画像診断は、T1 強調画像、T2 強調画像、ならびに FLAIR 画像またはプロトン密度強調画像の 3 種併用を必須としている。学習と評価に用いる画像を、T1 強調画像、T2 強調画像、FLAIR 画像の 3 種類の画像の組み合わせを変えた。

画像解析に用いたデータに関して、学習に用いた画像の枚数をグレード別に表 2 に示す。画像の枚数は、患者背景に示したグレード別の人数に依存するため、グレードが上がるにつれ、極端に画像の枚数が減少している。また、axial 別の枚数を表 3 に示す。MRI の撮影において、頭部の大きさに個人差があることなどにより、23 以降のアキシシャルは画像数が減少している。

実験に使用したモデルの概要を図 5 と表 4 に示す。畳み込み 2 回とプーリング 1 回の 3 層を 2 つ用い、ドロップアウトを 3 層用いた 13 層のモデル構造とした。

モデルの評価は、One vs Rest 方式を用いて混同行列を用い、accuracy (正診率)、error (誤診率)、TPR (感度) [16]、TFR (特異度) [16]、PPV (陽性的中率) [17]、NPV (陰性的中率) [17]を算出し、ROC 曲線 [18] [19]と、その下部面積を表す AUC [20]で評価を行った。

表 2 grade 別の画像の枚数

grade	T1	T2	FLAIR	The number of patients
0	12739	12753	12752	551
1	10222	10223	10212	441
2	2430	2430	2430	107
3	898	898	899	39
4	181	181	181	8
all	26470	26485	26473	1146

表 3 axial 別の画像の枚数

axial	T1	T2	FLAIR
1	1145	1146	1146
2	1146	1146	1145
3	1145	1146	1146
4	1146	1146	1145
5	1145	1146	1146
6	1146	1146	1145
7	1145	1146	1146
8	1146	1146	1145
9	1145	1146	1146
10	1146	1146	1145
11	1145	1146	1146
12	1146	1146	1145
13	1145	1146	1146
14	1146	1146	1145
15	1145	1146	1146
16	1146	1146	1145
17	1145	1146	1146
18	1146	1146	1145
19	1145	1146	1146
20	1146	1146	1145
21	1145	1146	1146
22	1146	1146	1145
23	864	867	867
24	374	375	374
25	29	29	29
26	2	2	2
all	26470	26485	26473




図 5 モデルの概要

表 4 モデルの概要

layer	type	Option	Output Shape	Params
1	Input			
2	Convolution	filters= 32, kernel_size=(3,3), padding=same, activation=relu	(None, 80, 80, 32)	896
3	Convolution	filters=32, kernel_size=(3,3), relu	(None, 78, 78, 32)	9248
4	Pooling	MaxPooling, pool_size=(2,2)	(None, 39, 39, 32)	0
5	Dropout	Dropout=0.25	(None, 39, 39, 32)	0
6	Convolution	filters= 32, kernel_size=(3,3), padding=same, activation=relu	(None, 39, 39, 32)	9248
7	Convolution	filters= 32, kernel_size=(3,3), padding=same, activation=relu	(None, 39, 39, 32)	9248
8	Pooling	MaxPooling, pool_size=(2,2)	(None, 19, 19, 32)	0
9	Flatten		(None, 11552)	0
10	Dropout	Dropout=0.25	(None, 11552)	0
11	Dense	output=512, activation=relu	(None, 512)	5915136
12	Dropout	Dropout=0.5	(None, 512)	0
13	Dense	output=5, activation=softmax	(None, 5)	2565

3.4. 共起ネットワーク図

共起ネットワークは、主に自然言語処理の分野で用いられ、文章に含まれる単語の出現頻度や単語間の関連性を可視化する手法である [21] [22]。

検査項目との関連性調査として、大脳白質病変のリスク因子である高血圧の傾向を共起ネットワーク図で示し、大脳白質病変の進行度との関係を調査した。

検査項目との関連性調査として、大脳白質病変のリスク因子である高血圧の傾向を共起ネットワーク図で示し、大脳白質病変の進行度との関係を調査した。糖尿病、脂質異常症、肥満、高血圧（正常血圧、正常高値血圧、高値血圧、I 度高血圧、II 度高血圧、III 度高血圧、（孤立性）収縮期高血圧）の 10 項目と、大脳白質病変の grade0～4 の計 15 項目を、共起ネットワーク図で可視化した。

患者一人につき、糖尿病、脂質異常症、肥満、高血圧（7 項目）のうち、罹患している病名を単語でテキスト化する。全ての患者について文を作成し、単語の出現数や、特定の単語の組み合わせの出現率によって、共起関係が形成される。罹患している患者が多い疾患ほど、ノードが大きく、エッジの距離が短く表現される。

4. 結果

4.1. 畳み込みニューラルネットワーク

4.1.1. 画像サイズの変更

モデルに入力する画像サイズを変化させたときの test accuracy の変化を調べた。test accuracy は、テストデータにおいて、各画像の grade を正しく判別した割合を表す。図 6 に、画像サイズを変更したときの判別性能の変化を示す。FLAIR 画像のみを用い、axial は 12 から 15 とした。横軸が入力した画像の縦横のピクセル数で、縦軸が test accuracy となる。最も高い性能を示したのは、80 ピクセルのときで、test accuracy は 0.8918 であった。80 ピクセルを頂点として画像サイズが増加または減少すると、判別性能はなだらかに減少していく傾向が見られた。以降の実験では、画像サイズはすべて 80 とした。




図 6 画像サイズを変化させたときの test accuracy の値

4.1.2. アキシタルの変更

学習と評価に使用した axial を変化させたときの、テストデータにおける予測精度の変化を図 7 に示す。また、図 7 の中から、同じ range のうち、最も高い test accuracy の値を示した時の結果を抜粋したものを表 5 に示す。

図 7 の横軸は、用いたアキシタルの最初の値を表し、縦軸は test accuracy を表す。

凡例は、range、すなわち、用いた axial の範囲の広さを表している。例えば、図 7 の緑色で示した range=4 において、

start axial が 1 のとき、学習と評価に用いた axial は 1 と 2 と 3 と 4、start axial が 2 のとき、2 と 3 と 4 と 5、以降、3 と 4 と 5 と 6、4 と 5 と 6 と 7 といったように、範囲を 1 ずつ移動させた。range は 2 から 9 まで実験を実施した。

図 7 を range 別に分けたものを図 8 から図 15 に示す。

図 7 を見ると、用いた axial の数に関わらず、start axial が 10 付近までは緩やかに判別性能が向上し、12 付近からある程度傾きを保ったまま判別性能が低下した。

表 5 を見ると、最も高い判別性能を示したのは、axial が 9 から 15、range が 7 のときで、test accuracy は 0.8958 であった。高い判別性能を示した range は 7 付近であり、axial はおおむね 9 から 15 であるという結果を得た。test accuracy の値が低かった時の range は 2 や 9 など、用いた axial の範囲が極端に広い場合や狭い場合であった。




図 7 range と axial の範囲を変化させたときの test accuracy の値




图 8 range=2




图 9 range=3




图 10 range=4




图 11 range=5




图 12 range=6




图 13 range=7




图 14 range=8




图 15 range=9

表 5 図 7 において, range 別で最も高い test accuracy を示した axial の値

start	end	range	test_accuracy
9	15	7	0.8958
9	14	6	0.8889
9	16	8	0.8835
12	16	5	0.8764
12	15	4	0.8735
12	14	3	0.8719
7	15	9	0.8604
11	12	2	0.8098

4.1.3. 撮影方法による違い

学習, 評価に用いる画像の組み合わせを変えたときの test accuracy の値を図 16 に示す. いずれの実験においても, axial は 9 から 15 (range=7) とした. 最も高い判別性能を示した撮影方法は FLAIR 画像と T1 強調画像を用いたときで, test accuracy は 0.9209 であった.




図 16 撮影方法の組み合わせを変えたときの判別性能の変化

4.1.4. 学習曲線

最も高い判別性能を示した時の学習曲線を図 17 に示す。図 17 上は、学習の経過に伴う精度の変化を示しており、横軸がエポック数、縦軸が精度を表す。図 17 下は、学習の経過に伴う損失の変化を示しており、横軸がエポック数、縦軸が損失を表す。

いずれの図においても、青色の線は学習用データにおける性能、オレンジ色の実線はテストデータにおける性能を示す。精度と損失の両方において、学習が進むに連れ、学習データ、テストデータの両方で性能が向上しているが、損失のみ、わずかに過学習の傾向が見られた。




図 17 学習曲線

4.1.5. グレード別評価

グレード別の混同行列をヒートマップで表したものを図 18 に示す。横軸は、テストデータに対してモデルが予測した grade で、縦軸は実際のグレード、すなわち正解ラベルを表す。通常、2 値分類の混同行列では、TP, TN, FP, FN の 2x2 の混同行列で表されるが、本タスクは 5 つの grade を予測する多クラス分類であるため、5x5 の混同行列によって表現される。

グレード別に性能評価を行うため、注目したいグレードのみを正例、それ以外を負例と見なして、2 値分類で評価を行う One vs Rest 方式を用いた。例えば、grade1 の判別性能を評価したいとき、図 19 のように grade1 とそれ以外でクラスを分けることで、表 6 のような一般的な 2 値分類の混同行列を作成することができる。

この方式を用いて、正解率、エラー率、感度、特異度、陽性的中率、陰性的中率を grade 別に評価した結果を表 7 に示す。また、縦軸を感度、横軸を 1-特異度、すなわち偽陽性率として、グレード別に ROC 曲線を描画したものを図 20 に示す。grade0 と grade1 はほぼ同じ性能であったが、グレードが上がるにつれ、判別性能は向上しているという結果が得られた。モデルの性能は、ROC 曲線の下部面積を表す AUC によって評価される。

各 grade の AUC は、grade0 が 0.9814, grade1 が 0.9800, grade2 が 0.9905, grade3 が 0.9977, grade4 が 0.9998 となった。




図 18 混同行列をヒートマップで表したもの




図 19 One vs Rest 方式の概念図

表 6 2 値分類における混同行列

		True	
		Positive	Negative
Predict	Positive	TP	FP
	Negative	FN	TN

表 7 グレード別の判別性能

grade	accuracy	error	TPR	TFR	PPV	NPV
grade 0	93.19%	6.81%	90.82%	95.56%	95.34%	91.24%
grade 1	92.79%	7.21%	91.61%	93.53%	89.80%	94.72%
grade 2	98.00%	2.00%	95.41%	98.24%	82.76%	99.59%
grade 3	99.35%	0.65%	94.78%	99.49%	84.50%	99.85%
grade 4	99.90%	0.10%	92.31%	99.95%	92.31%	99.95%




図 20 ROC 曲線

4.2. 共起ネットワーク図

大脳白質病変の 5 つの grade と、高血圧を重症度に応じて分類した 7 項目、肥満、糖尿病、脂質異常症の 15 項目を共起ネットワーク図で可視化した結果を図 21 に示す。

ノードの大きさと色の濃さはサンプル数を表しており、ノード間の距離は共起関係の強さを示している。そのため、距離が近いノードほど、その 2 つの疾患を保有している関連性が高いことを表す。grade0 や grade1 は、正常血圧や正常高値血圧など、正常な範囲かそれに近い血圧を表すノードとの距離が近く、grade2 はそれらの血圧のノードからの距離が離れ、高齢者に見られやすい（孤立性）収縮期高血圧との距離が近いという結果が得られた。

これは、grade0 や grade1 の患者は、正常かそれに近い血圧を有している割合が高く、grade2 になると、高血圧を有している割合が高くなることを表しており、大脳白質病変が進行している患者ほど、より重度の高血圧を有していることが示唆された。




図 21 共起ネットワーク図

5. 考察

畳み込みニューラルネットワークによるグレード予測では、range の値が大きいほど、学習に用いる画像数が増加するため、精度が上昇する傾向にある。一方で、range を極端に増やすと、大脳白質病変が見られない眼球側や頭頂部側の画像が学習データに含まれるため、精度は低下したと考えられる。

撮影方法別の畳み込みニューラルネットワークを用いたグレード予測では、FLAIR 画像は目視でも大脳白質病変を識別しやすく、畳み込みによって特徴が取り出しやすいために、FLAIR 画像を用いた時の精度が高くなったと考えられる。T2 強調画像も目視で病変を識別しやすい一方で、大脳周辺部分が高信号領域として白く描画されており、病変との区別がつきにくいために、T2 強調画像を用いた時の判別性能が低かったと考えられる。

共起ネットワーク図においては、グレード 3 以上のサンプル数が少ないために共起関係が形成されず、ノードとして描画されなかったと考えられ、高度の大脳白質病変を有する患者と健診項目との関連性を十分に見ることができなかった。

健診データの検査項目との関連性に関しては、降圧剤などの薬剤使用の有無、脳梗塞などの既往歴との関連性を含めて検討することで、大脳白質病変とそのリスク因子との関連性をより幅広く検証していきたい。

参考文献

- [1] 辻一郎. (2004). 健康寿命と介護予防. 理学療法の歩み, 15(1), 2-8..
- [2] 尾島俊之. (2015). 健康寿命の算定方法と日本の健康寿命の現状. 心臓, 47(1), 4-8..
- [3] Debette, S., Beiser, A., DeCarli, C., Au, R., Himali, J. J., Kelly-Hayes, M., ... & Seshadri, S. (2010). Association of MRI markers of vascular brain injury with incident stroke, mild cognitive impairment, dementia, and mortality: the Framingham Offspring.
- [4] Shinohara Y, Tohgi, H, Hirai S, et al. Effect of the Ca Antagonist Nilvadipine on Stroke Occurrence or Recurrence and Extension of Asymptomatic Cerebral Infarction in Hypertensive Patients with or without History of Stroke (PICA Study) : 1. Design and.
- [5] Frisoni, G. B., Galluzzi, S., Pantoni, L., & Filippi, M. (2007). The effect of white matter lesions on cognition in the elderly—small but detectable. *Nature Clinical Practice Neurology*, 3(11), 620-627..
- [6] Breteler, M. M. B., Van Swieten, J. C., Bots, M. L., Grobbee, D. E., Claus, J. J., Van Den Hout, J. H. W., ... & Hofman, A. (1994). Cerebral white matter lesions, vascular risk factors, and cognitive function in a population - based study: the Rotterdam Stu.
- [7] Debette, S., & Markus, H. S. (2010). The clinical importance of white matter hyperintensities on brain magnetic resonance imaging: systematic review and meta-analysis. *Bmj*, 341..
- [8] 今泉俊雄. (2016). 大脳白質病変の成因と臨床. 脳卒中, 38(2), 69-76..
- [9] Shinkawa, Y., Yoshida, T., Onaka, Y., Ichinose, M., & Ishii, K. (2019) . Mathematical modeling for the prediction of cerebral white matter lesions based on clinical examination data. *PloS one*, 14 (4) , e0215142..
- [10] 篠原幸人. (1997). VI. 脳検診（脳ドック）の意義と現状. 日本内科学会雑誌, 86(5), 787-791..
- [11] Naqvi, T. Z., & Lee, M. S. (2014). Carotid intima-media thickness and plaque in cardiovascular risk assessment. *JACC: Cardiovascular Imaging*, 7(10), 1025-1038..

- [12] 日本高血圧学会高血圧治療ガイドライン作成委員会編 (2019)『高血圧治療ガイドライン 2019』ライフサイエンス出版社.
- [13] *De Leeuw, F. E., de Groot, J. C., Achten, E., Oudkerk, M., Ramos, L. M. P., Heijboer, R., ... & Breteler, M. M. B. (2001). Prevalence of cerebral white matter lesions in elderly people: a population based magnetic resonance imaging study. The Rotterdam Sc.*
- [14] 國枝琢也, 内山良一, 原武史, 藤田広志, 加藤博基, 浅野隆彦, ... & 岩間亨. (2008). クラスタリングを用いた脳ドック MR 画像における無症候性大脳白質病変の検出法. *Medical Imaging Technology*, 26(1), 39..
- [15] 脳ドックのガイドライン 2019 改訂委員会編 (2019)『脳ドックのガイドライン 2019 』響文社.
- [16] *Altman, D. G., & Bland, J. M. (1994). Diagnostic tests. 1: Sensitivity and specificity. BMJ: British Medical Journal*, 308(6943), 1552..
- [17] *Altman, D. G., & Bland, J. M. (1994). Statistics Notes: Diagnostic tests 2: predictive values. Bmj*, 309(6947), 102..
- [18] *Park, S. H., Goo, J. M., & Jo, C. H. (2004). Receiver operating characteristic (ROC) curve: practical review for radiologists. Korean journal of radiology*, 5(1), 11-18..
- [19] *Cook, N. R. (2008). Statistical evaluation of prognostic versus diagnostic models: beyond the ROC curve. Clinical chemistry*, 54(1), 17-23..
- [20] *Bradley, A. P. (1997). The use of the area under the ROC curve in the evaluation of machine learning algorithms. Pattern recognition*, 30(7), 1145-1159..
- [21] *Hirsch, L., & Andrews, S. (2016, July). Visualising text co-occurrence networks. In CEUR Workshop Proceedings (Vol. 1637, pp. 19-27). Tilburg University..*
- [22] *Stuart, K., & Botella, A. (2009). Corpus linguistics, network analysis and co-occurrence matrices. International Journal of English Studies*, 9(3), 1-20..

謝辞

本論文は，筆者が公立諏訪東京理科大学工学部情報応用工学科在学中の研究成果をまとめたものです．本研究の遂行と論文執筆にあたり，多大なるご指導ご支援をいただいた石井一夫教授には心より感謝申し上げます．本研究を行うにあたり，貴重なデータを提供していただいた一般社団法人巨樹の会新武雄病院の皆様に心から感謝申し上げます．